**존 써얼의 중국어 방**

■

- 사람의 인지 능력을 컴퓨터로 시뮬레이트 하려는 시도에 대한 심리학적·철학적 의의가 무엇인지 답하기 위해서 강한 인공지능과 약한 인공지능을 구분.
    - 약한 인공지능(weak AI): 마음 연구에서 컴퓨터의 주된 가치는, 강력한 도구를 제공한다는 것.
    - 강한 인공지능(strong AI): 잘 프로그램 된 컴퓨터는 어떤 것을 이해하고 인지 상태를 가진다는 점에서 마음임. 컴퓨터가 인지 상태를 가지므로 심리학적 설명을 단순히 시험하는 것이 아니라 그 자체로 설명임.
- 써얼은 약한 인공지능에 관한 주장에 반대하지 않음. 여기서 논의되는 인공지능은 강한 인공지능.

■

- 섄크(Schank)의 프로그램
    - 프로그램의 목표는 인간의 이야기 이해 능력을 시뮬레이트하는 것.
    - 인간의 이해 능력의 특징은 질문에 대한 정보가 이야기에 명시되지 않은 경우에도 대답할 수 있다는 것.
- 예)
    - 이야기: “어떤 사람이 음식점에서 손님이 햄버거를 주문했는데, 나온 햄버거가 너무 타고 뻣뻣했다. 손님은 화가 나서 돈을 지불하지 않고, 팁도 주지 않고, 음식점을 뛰쳐나갔다.”
    - 질문: 그 손님은 그 햄버거를 먹었는가?
    - 대답: 아니오.
- 컴퓨터가 이러한 대답을 하려면, 음식점에 간 인간이 가지는 종류의 정보에 대한 “표상”을 가져야 함.
- 섄크의 프로그램은 강한 인공지능 옹호자들의 주장을 뒷받침함.
- 강한 인공지능 옹호자들의 주장
    - 주장(1): 기계가 말 그대로 이야기를 이해하고, 질문에 대답한다.
    - 주장(2): 기계/프로그램은, 사람이 이야기를 듣고 질문에 대답하는 능력을 설명한다.
- 써얼은 섄크의 프로그램이 이러한 주장들을 전혀 지지하지 않는다는 입장.

■ 써얼의 사고 실험 (중국어방)

- 마음에 관한 어떠한 이론을 시험하는 방법은, 그 이론이 모든 마음이 작동하는 원리라고 말하는 원리에 따라 실제로 내 마음이 작동하면 어떨지를 스스로에게 묻는 것.
- 중국어를 전혀 모르는 내가 어떤 방에 갇혀 있음.
    - 방 안에 있는 책(1): 중국어 질문이나 문장들이 적힌 커다란 책(입력 기호들의 집합)
    - 방 안에 있는 책(2): 특정 중국어 기호 배열이 들어왔을 때 어떤 중국어 기호 배열을 내보내야 하는지를 영어로 설명한 규칙서.
    - 규칙은 영어로 되어 있고 나는 영어를 모국어로 삼는 다른 사람들처럼 그 규칙을 잘 이해함.
    - 규칙을 통해 한 집합의 형식 기호를 다른 집합의 형식 기호와 연결할 수 있음.
    - 방 안에 있는 책(3): 응답에 사용할 중국어 문장들이 적힌 책. 책(2)의 규칙에 따라 적절한 문장을 찾아 바깥으로 전달함.
    - (3)의 요소를 (1)과 (2)와 관련시키는 것이 가능
    - (1)을 “스크립트”(a script), (2)를 “이야기들”, (3)을 “질문들”이라고 부름.
    - (3)에 대해 내가 대답할 때 사용하는 기호를 “질문에 대한 대답”이라고 부름.
    - 영어로 쓴 규칙의 집합을 “프로그램”이라고 부름.
- 어떤 사람들이 나에게 영어로 된 이야기를 주었다고 가정하자.
    - 나는 그 이야기를 이해할 수 있음.
    - 내가 지시에 따라 중국어 기호를 처리하는 데 익숙해지고, 프로그래머도 프로그램을 작성하는 데 익숙해짐.
    - 방 바깥에 있는 누군가의 관점에서 볼 때 질문에 대한 나의 대답이 중국어가 모국어인 사람의 대답과 구별할 수 없을 정도가 되었다고 하자.
    - 그러나 나는 중국어를 전혀 이해하지 못하고 형식 기호를 처리하여 대답을 작성한 것.
- 강한 인공지능의 지지자들이 하는 주장을 사고 실험에 비추어 검토할 것임.

■ 주장(1)

- 나는 중국어가 모국어인 사람의 입력/출력과 구별할 수 없는 입력/출력을 가지며, 당신이 원하는 모든 형식 프로그램을 가질 수 있지만, 여전히 나는 어떠한 이야기도 이해하지 못함.
- 같은 이유로, 섄크의 컴퓨터도 어떤 언어든 이야기를 전혀 이해하지 못함.

• 중국어의 경우 컴퓨터는 나이고, 내가 컴퓨터가 아닌 경우 컴퓨터는 내가 아무 것도 이해하지 못한 경우보다 이해를 더 잘하지 않기 때문.

■ 주장(2)

- 컴퓨터와 컴퓨터 프로그램은 이해에 대한 충분 조건을 제공하지 않음.
  • 컴퓨터는 기능한 것이고 이해는 없었기 때문.
- 컴퓨터와 프로그램은 이해에 대한 필요 조건을 제공하는가?
- 내가 영어로 된 이야기를 이해할 때 하는 일과 중국어 기호를 조작할 때 하는 일이 정확히 같거나 매우 비슷하다는 강한 인공지능 지지자의 주장이 그럴듯하게 들리는 것은, 두 가지 가정을 하기 때문임.
  • 가정(1): 모국어 화자와 같은 입력과 출력을 가지는 프로그램을 구성하는 것이 가능함.
  • 가정(2): 모국어 화자들도 어떠한 프로그램의 예화인, 어떤 수준의 기술(description)을 가짐.
- 써얼은 그러한 경험적 가능성이 있지만 그것이 참이라고 믿을 이유는 거의 없다고 함.
  • 앞의 사례에서 보여준 것은, 컴퓨터 프로그램이 이야기에 대한 나의 이해와 무관하다는 점.
  • 중국어의 경우, 인공지능이 프로그램을 통해 나에게 투입할 수 있는 모든 것을 내가 가지지만, 나는 아무 것도 이해하지 못함.
  • 영어의 경우, 나의 이해가 컴퓨터 프로그램과 관련된다고 가정할 이유가 전혀 없지만, 나는 이해함.
  • 프로그램이 순수하게 형식적으로 규정되는 요소에 대한 계산 작동으로 정의되는 한, 이러한 작동은 이해와 관련이 없음.
  • 따라서 충분 조건은 분명히 아니고 필요 조건이나 이해에 관한 공헌을 한다고 생각할 근거는 전혀 없음.
- 여기서 핵심은 순수하게 형식적인 원리를 컴퓨터에 입력하더라도 그러한 원리들은 이해에 관한 충분하지 않다는 것.
  • 사람은 어떠한 이해 없이 형식적 원리들을 따를 수 있을 것이기 때문.
  • 내가 영어를 이해할 때 내가 어떤 형식적인 프로그램을 조작한다고 가정할 이유가 없기 때문에, 그러한 원리가 필요하거나 도움이 된다고 생각할 이유도 없음.

■

- 써얼은 인공 지능 연구자들에게 이러한 사례를 소개함.
  • 연구자들은 그에 대한 적절한 답변이 무엇인지에 대한 일치된 의견에 도달하지 못함.
- 그들의 반응에 대한 고찰을 하기 전에 우선 “이해”에 대한 일반적인 오해를 막고자 함.
- 써얼의 비판자들의 지적
  • 이해의 여러 다른 정도들이 있음.
  • “이해”는 단순한 이항 술어가 아님.
  • 이해에는 여러 종류와 수준이 있고, “x understands y”라는 형식의 명제에 배중률이 직접 적용될 수 없는 경우가 발생함.
  • 많은 경우 x가 y를 이해하는지 여부는 단순한 사실의 문제가 아니라 판단을 요구하는 문제임.
- 써얼은 비판자들의 지적이 맞는 말이지만, 논의하는 문제와 관계없다고 함.
  • “이해”라는 말이 문자 그대로 적용되는 분명한 사례와 그것이 적용되지 않는 분명한 사례가 있고, 이 두 종류의 사례가 이 논의에 필요한 전부이기 때문.
  • “자동 온도 조절 장치는 온도 변화를 지각한다”는 등의 표현은, 우리가 지향성(intentionality)을 인공물에게도 확장한다는 사실과 연관됨.
  • 그러나 이는 비유일 뿐이며, 내가 영어를 이해할 때의 의미가 아님.
- 뉴웰과 사이먼은 컴퓨터의 인지와 사람의 인지가 같은 종류라고 주장함.
  • 썰은 컴퓨터의 이해는 부분적이거나 불완전한 것이 아니라 제로(0)라고 함.

■ 비판(1): 체계 이론의 비판

방에 갇힌 사람이 이야기를 이해하지 못하는 것은 사실이지만, 그 사람은 전체 체계의 일부일 뿐이며 체계 전체는 이야기를 이해함.

이해는 개인에게 귀속되는 것이 아니라 개인을 한 부분으로 삼는 체계 전체에 귀속됨.

■ 써얼의 반박

- 체계의 모든 요소들을 개인에게 내면화하자.
  • 장부에 적힌 규칙과 중국어 기호의 데이터 뱅크를 암기하여 모든 것을 개인의 머릿속에서 계산하는 것.
  • 방을 제거하고 야외에서 일한다고 가정할 수도 있음.

- 이 경우에도 그 개인은 중국어를 전혀 이해하지 못함.
  - 체계는 더더욱 이해하지 못함.
  - 개인에게 없고 체계에 있는 것이 없기 때문.
  - 체계는 개인의 일부이므로 개인이 이해하지 못한다면 체계도 이해할 방법이 없음.

■ 비판(2): 로봇

샌크의 프로그램을 가진 컴퓨터를 로봇 속에 넣고, 그 컴퓨터가 로봇을 조절하여, 감지하고, 행동하게 만들면, 이 로봇은 진정한 '이해력'과 '마음의 상태'를 가진 것이다.

■ 써얼의 반박

로봇 응답은, 로봇의 행동은 외부 세계와 관련된 단순 인과관계로서, 여전히 형식 기호 처리일 뿐이다. "감각 장치"나 "동작(모터)"이 더해져도 '이해' 특히 '지향성(intentionality)'에 더해지는 것이 없다. 로봇 속에 컴퓨터 대신 사람을 넣고 한자 형식 부호 처리 실험을 해도 상황이 똑같다.

■ 비판(3): 두뇌 시뮬레이션

프로그램/기계를 생각하자. 그 기계는 중국어로 된 이야기와 질문을 입력 받고, 이 이야기를 이해하고 대답하는 중국 사람의 두뇌 속 시냅스와 뉴론의 작동 순서들을 흉내 낸다고 하자. 병렬 처리도 포함하자. 그러면 기계가 이야기를 '이해'한 것이다.

■ 써얼의 반박

심성이 어떻게 작동하느냐를 알기 위해 두뇌가 어떻게 작동하는지를 알 필요는 없다. 강한 인공지능에서 마음-두뇌 관계는 프로그램-굳은모 관계이므로 신경생리학 없이 우리는 마음을 이해할 수 있다. 뉴런 대신에 물 파이프들과 밸브들로 이루어진 계를 생각해 보자. 그 속에 영어만을 이해하는 사람이 배치되어 있어서 그가 한자들을 받으면, 어떤 밸브들을 열고 닫을지를 지시한 영어로 된 프로그램을 살펴본다. 밸브 조절이 모두 제대로 되면 한자로 된 답이 마지막 파이프에서 튀어나온다. 뉴론 작용들을 흉내 낸 이 계 속에 '이해력'은 없다. 형식 구조만을 흉내 내는 것은, 지향성의 상태를 만들어 내는 것이 아니다.

■ 비판(4): 결합

위 세 가지 경우를 모두 합친 경우는 어떤가? 두뇌 모양의 컴퓨터를 가진 로봇이 있고, 그 컴퓨터는 뉴론과 시냅스에 대해 프로그램 되어 있고, 로봇의 행동이 사람의 행동과 구분이 아니 된다고 하자. 그럼 우리는 그 계에게 지향성을 부여할 수밖에 없다.

■ 써얼의 반박

우리가 로봇에게 '지향성'을 부여하는 것은 형식 프로그램과는 상관이 없다. 로봇이 충분히 우리처럼 보이고 행동할 때, 우리는 로봇 속에 마음의 상태를 만들어 낼 수 있는 기계 장치가 들어있다고 가정할 뿐이다. 그런 가정 없이 그 기계의 행동을 우리가 파악할 수 있다면, 특히 그 로봇의 행위가 형식 프로그램의 결과라는 것을 아는 순간, 우리는 그 기계에게 지향성을 부여하지 않을 것이다.

■ 비판(5): 다른 사람의 마음

다른 사람들이 한자를 이해한다는 사실을 당신이 어찌 아는가? 그들의 행동을 보고 알 뿐이다. 컴퓨터가 행동 시험을 통과한다면, 컴퓨터의 인지 상태도 인정된다.

■ 써얼의 반박

내가 다른 사람의 인지 상태를 어떻게 아느냐가 초점이 아니라, 내가 다른 사람들의 인지 상태를 인정할 때, 그 인지 상태라는 것이 무엇인가 하는 것이 초점이다. 인지 과학에서 우리는 마음의 실재성과 파악 가능성을 전제로 한다.

■ 비판(6):

당신이 가정하는 것은, AI가 단지 유추와 디지털 컴퓨터에 관한 것이라는 점이다. 그러나 이는 현재의 기술 수준일 뿐이다. 궁극적으로는 이 인과 과정을 가지는 장치가 만들어질 것이고 그 것이 AI일 것이다.

■ 써얼의 반박

이 말은 AI의 정의를 바꾸는 것이다.

> 원래 AI: '마음의 과정은 형식적으로 정의된 요소들에 관한 계산 과정들이다.'

이제 AI를 위처럼 새로 정의한다면 써얼은 부분적으로 여기에 동의한다. 우리가 기계에게 '이해'하는 능력을 줄 수 있다. 그러나 그 연산이 오직 형식적으로 정의된 요소들에 관한 계산 과정으로 정의된 기계에게는 '이해'하는 능력을 줄 수 없다.

■ 써얼의 주장 정리

A. 서얼이 영어를 이해하고 '지향성'을 가지는 것은 서얼이 생물적 구조를 가진 유기체이며, 이 구조는 어떤 조건에서 지각, 행동, 이해, 학습 그밖의 '자의'적인 현상을 인과적으로 일으킬 수 있는 능력을 가지기 때문이다.

B. 순수한 형식계 모형은 '지향성'을 주기에 충분하지 않다. 형식계의 특성들은 형식의 다음 단계를 만들어 낼 수 있을 뿐 인과적 능력이 없다. 두뇌 작동에 관한 것은, 시냅스의 순서가 만드는 형식 그림자가 아니라, 그 순서가 만드는 실제 성질이다. 많은 strong AI가 그림자의 가장자리만 그려놓고 그림자가 실제 것이라고 주장한다.

C. 프로그램 구현 자체는 '이해'를 위한 충분 조건이 아니다. 형식 기호 처리 자체에는 '지향성'이 없다. 문법만 있고 어의가 없는 셈이다.

D. 마음/두뇌 <-> 프로그램/굳은모 관계는 잘못된 생각이다.

1. 프로그램과 그 구현을 분리하여 생각하는 것은 한 프로그램이 여러 방법으로 구현될 수 있음을 뜻한다. - 파이프 배관, 바람개비, 영어로 말하기, ... 그러나 정작 한자로 된 이야기를 이해하는 사람은 없다.

2. 프로그램은 순전히 형식적이다. 그러나 자의적 상태는 형식적 방식이 아니다. 비가 온다고 믿는 것은 어떤 형식으로 정의된 것이 아니라, 만족이라는 조건을 가진 마음의 내용물로서 정의된다.

3. 마음의 상태와 사건은 마음의 생산물이다. 그러나 프로그램은 컴퓨터의 생산물이 아니다. 컴퓨터 흉내 내기(simulation)가 실제를 나타낸다는 생각이 의심스럽다.

E. AI가 정신 현상을 설명할 것이라는 착각이 생긴 이유들.

1. "정보 처리"라는 용어가 주는 착각
[사람의 두뇌가 정보처리를 한다. -- 컴퓨터가 정보처리를 한다.]
성격이 다른 두 용어들이다. 사람은 정보를 처리하지만, 컴퓨터는 형식 기호를 처리할 뿐이다.

2. 많은 AI 속에 행동주의나 조작주의가 들어있다.
잘 프로그래밍된 컴퓨터에, 사람과 비슷하게, 입출력 양상이 있으므로
컴퓨터의 마음 상태가 사람의 마음 상태와 비슷하다고 가정하는 경향이 있다.

3. 이 조작주의가 이원론의 형태와 결합되어 있다.
strong AI에서 하드웨어인 뇌가 주어지면 그 속에서 프로그램이 독립적으로 작동한다는 착각이 깔려 있다.
실제 사람의 정신 현상은, 실제 사람 두뇌의 물리-화학적 성질에 의존한다.
특정 심성이 뇌의 실제 성질과 직접 연결되지 않는다고 가정하는 것은일종의 이원론적 가정이다. (원래 데카르트의 이원론과는 다르지만)

결론:
F. 기계가 생각할 수 있는가?
두뇌, 또는 두뇌와 같은 능력을 가진 특별한 종류의 기계만이 생각을 할 수 있다.
strong AI는 프로그램이고 기계 자체는 아니다.

G. 마음은 형식 처리에 관한 것으로서 특정 물질적인 것과는 상관이 없다는 착각이 사람들 사이에 박혀있다.

H. 지향성을 만들기 위해 두뇌가 하는 것이 무엇이든, 지향성은 프로그램들 속에 존재하지 않는다. 프로그램은 지향성을 만들어 내기에 충분하지 않다.